

LABORATORIO NUMERO 01

Informe - Taller 1 Programación Científica

Francisco Cortés, Fabián Díaz e Ignacia Peña

Universidad Católica del Norte, Coquimbo, Coquimbo, Chile

Author for correspondence: Francisco Cortés, Ignacia Peña, Fabián Díaz, Email: francisco.cortes07@alumnos.ucn.cl, Ignacia.pena@alumnos.ucn.cl, fabian.diaz03@alumnos.ucn.cl.

Abstract

El presente trabajo tuvo como objetivo modelar y analizar una red de artículos de Wikipedia mediante un grafo dirigido implementado en Python bajo programación orientada a objetos. Para ello, se procesó un subconjunto del dataset Graphs SNAP Wiki compuesto por 10.000 enlaces entre artículos y 10.000 relaciones artículo-categoría, construyendo una estructura basada en listas de adyacencia. Sobre el grafo se aplicaron métricas de grado de entrada y salida, recorridos BFS y DFS, verificación de existencia de caminos y una versión simplificada del algoritmo PageRank. Los resultados permitieron identificar artículos estructuralmente relevantes, destacando Buprestidae, Buprestoidea, Visual kei y Schizopodidae. Además, la relación entre PageRank y categorías evidenció núcleos temáticos asociados a taxonomía biológica y música japonesa. Se concluye que el sistema permite analizar conectividad, relevancia y organización temática dentro del subconjunto estudiado.

This study developed a Python-based system to model and analyze a network of Wikipedia articles represented as a directed graph using object-oriented programming principles. A subset of the Graphs SNAP Wiki dataset was used, including 10,000 article links and 10,000 article-category relationships, in order to maintain manageable execution times. The system was designed to represent articles, categories, and their connections, allowing the implementation of graph traversal algorithms such as BFS and DFS, path verification, structural metrics, and a simplified PageRank algorithm. The results showed that the network presents an uneven distribution of connectivity, where a small number of articles concentrate most of the structural relevance. The study demonstrates that graph analysis techniques can be effectively applied to real-world datasets to identify connectivity patterns and relevant nodes.

Keywords: teoría de grafos, grafos dirigidos, pagerank, bfs, dfs, programación orientada a objetos, python, redes de wikipedia

Introducción

En la era digital actual, el acceso a grandes volúmenes de información ha generado la necesidad de desarrollar herramientas capaces de organizar, representar y analizar estructuras de datos cada vez más complejas. Un ejemplo claro de esto es Wikipedia, una plataforma de conocimiento colaborativo cuya información se encuentra interconectada mediante enlaces entre artículos relacionados.

Desde una perspectiva computacional, esta estructura puede ser representada como un grafo dirigido, donde cada artículo corresponde a un nodo y cada enlace representa una arista orientada hacia otro artículo. Este tipo de representación permite aplicar conceptos de teoría de grafos para estudiar patrones de conectividad, identificar nodos relevantes y comprender la organización interna de redes complejas (Newman, 2018).

El análisis de grafos posee múltiples aplicaciones en áreas como motores de búsqueda, redes sociales, sistemas de recomendación y organización de información digital. Dentro de este contexto, PageRank corresponde a uno de los algoritmos más conocidos para estimar la relevancia de nodos en una red, considerando no solo la cantidad de enlaces recibidos, sino también la importancia de los nodos que los generan (Page et al., 1999).

En este contexto, el presente trabajo busca modelar y analizar

una red de artículos de Wikipedia utilizando programación orientada a objetos en Python. Para ello, se emplean datos reales obtenidos desde el dataset Graphs SNAP Wiki disponible en Kaggle, el cual contiene información estructural sobre redes derivadas de Wikipedia (Kaggle, s. f.). A través de este análisis se busca comprender la estructura de la red e identificar artículos relevantes dentro del subconjunto de datos estudiado.

Objetivos

Objetivo general

Desarrollar un sistema en Python, utilizando programación orientada a objetos, que permita modelar y analizar la red de artículos de Wikipedia, identificando nodos relevantes mediante métricas estructurales y un algoritmo simplificado de PageRank.

Objetivos específicos

- Procesar y cargar los datos provenientes del dataset Graphs SNAP Wiki de Kaggle, considerando artículos, enlaces y categorías asociadas.
- Modelar artículos, categorías y sus relaciones mediante programación orientada a objetos en Python.
- Construir un grafo dirigido utilizando listas de adyacencia para representar la red de enlaces entre artículos de

Wikipedia.

- Implementar algoritmos de recorrido como BFS y DFS para analizar la conectividad de la red y determinar la existencia de caminos entre artículos.
- Calcular métricas estructurales, como grado de entrada y grado de salida, para identificar nodos con alta conectividad dentro del grafo.
- Implementar una versión simplificada del algoritmo PageRank para determinar la relevancia de los artículos dentro de la red.
- Analizar e interpretar los resultados obtenidos mediante métricas, rankings y visualizaciones generadas por el sistema.

Dataset Utilizado

Para el desarrollo del presente proyecto se utilizó el dataset público Graphs SNAP Wiki, disponible en Kaggle. Este conjunto de datos contiene información estructural asociada a redes derivadas de Wikipedia, incluyendo relaciones entre artículos, enlaces internos y categorías asociadas (Kaggle, s. f.).

Desde el punto de vista computacional, este dataset permite representar una parte de Wikipedia como un grafo dirigido, donde cada artículo corresponde a un nodo y cada enlace entre artículos representa una arista orientada. Esta forma de representación resulta adecuada para analizar patrones de conectividad, relevancia estructural y relaciones entre contenidos dentro de una red de información (Newman, 2018). Para el desarrollo del sistema se utilizaron específicamente los siguientes archivos:

- `wiki-topcats.mtx`: Contiene las relaciones de enlace entre artículos de Wikipedia. Cada par de identificadores representa una arista dirigida desde un artículo de origen hacia un artículo de destino. Este archivo fue utilizado como base para construir la lista de adyacencia del grafo.
- `wiki-topcats_Categories.mtx`: Contiene las relaciones entre artículos y categorías. Cada par de identificadores permite asociar un artículo con una categoría determinada, enriqueciendo el análisis estructural con información temática.
- `wiki-topcats_pagenames.txt`: Contiene los nombres asociados a los identificadores numéricos de cada artículo. Este archivo permite reemplazar los IDs por nombres comprensibles durante la presentación de resultados y el análisis.
- `wiki-topcats_Category_names.txt`: Contiene los nombres asociados a los identificadores de cada categoría presente en el dataset. Su uso permite interpretar las asociaciones artículo-categoría de forma más clara.

Debido al tamaño del dataset original, se decidió trabajar con un subconjunto limitado de datos. Específicamente, se procesaron hasta 10.000 enlaces entre artículos y hasta 10.000 relaciones artículo-categoría. Esta decisión permitió mantener tiempos de ejecución razonables, facilitar las pruebas del sistema y desarrollar un análisis estructural manejable dentro del contexto académico del taller.

El uso de un subconjunto implica que los resultados obtenidos deben interpretarse como representativos únicamente de la

porción de red procesada, y no necesariamente de la totalidad de Wikipedia. Sin embargo, dicho subconjunto conserva relaciones suficientes para aplicar recorridos, calcular métricas estructurales y estimar relevancia mediante PageRank.

Diseño e implementación

El sistema fue desarrollado en Python utilizando el paradigma de programación orientada a objetos, con el propósito de representar de manera modular los componentes principales de una red de artículos de Wikipedia. Esta decisión permitió separar responsabilidades entre las entidades del dominio, la estructura del grafo, la lectura de datos y la ejecución de los algoritmos de análisis.

El diseño del sistema se organizó en torno a cuatro componentes principales: “Artículo”, “Categoría”, “GrafoArticuloCategoría” y “LectorArch”. La clase Artículo representa cada nodo del grafo, almacenando su identificador, nombre, categorías asociadas, enlaces entrantes y enlaces salientes. La clase Categoría representa las categorías presentes en el dataset y mantiene la relación con los artículos asociados. La clase GrafoArticuloCategoría actúa como estructura central del sistema, administrando los artículos, las categorías y las conexiones entre nodos. Finalmente, la clase LectorArch se encarga de procesar los archivos de entrada y transformar sus datos en estructuras utilizables por el programa.

La arquitectura del sistema se resume en la tabla 1.

Tabla 1. Arquitectura del sistema

Componente	Descripción
Artículo	Representa cada nodo del grafo almacenando identificador, nombre, categorías, enlaces entrantes y salientes.
Categoría	Representa las categorías del dataset y mantiene los artículos asociados.
GrafoArticuloCategoría	Administra la estructura del grafo, incluyendo artículos, categorías, adyacencia, métricas, recorridos y PageRank.
LectorArch	Lee archivos .mtx y .txt, filtra datos y transforma registros para el sistema.
main.py	Coordina la ejecución general del programa: Carga de datos, construcción del grafo, ejecución de algoritmos y exportación de resultados

La estructura orientada a objetos del sistema se representa mediante el siguiente diagrama de clases, donde se muestran las clases principales, sus atributos, métodos y relaciones dentro del proyecto.

El diagrama de clases muestra que el sistema se organiza en torno a las clases Artículo, Categoría, GrafoArticuloCate-




Figura 1. Diagrama de clases del sistema implementado. Fuente: elaboración propia.

goria y LectorArch. La clase GrafoArticuloCategoria actúa como componente central, ya que administra las colecciones de artículos y categorías, además de la lista de adyacencia que representa las conexiones dirigidas entre artículos.

La relación entre GrafoArticuloCategoria y Artículo indica que el grafo contiene múltiples artículos, mientras que la relación con Categoria indica que también administra las categorías asociadas al conjunto de datos. Por su parte, LectorArch cumple una función auxiliar, encargándose de leer archivos .mtx y .txt para entregar la información necesaria durante la construcción del grafo.

La estructura principal del grafo fue implementada mediante una lista de adyacencia basada en diccionarios de Python. En esta representación, cada identificador de artículo se utiliza como clave, y su valor asociado corresponde a una lista con los artículos hacia los cuales existe un enlace dirigido. Esta alternativa resulta más eficiente que una matriz de adyacencia para este caso, debido a que la red de Wikipedia es dispersa: no todos los artículos se conectan con todos los demás. Por lo tanto, almacenar únicamente las conexiones existentes reduce el uso de memoria y facilita el recorrido del grafo.

El proceso de carga de datos se realizó a partir de archivos del conjunto wiki-topcats. En primer lugar, se leyeron los enlaces entre artículos desde el archivo wiki-topcats.mtx, interpretando cada par de identificadores como una arista dirigida desde un artículo de origen hacia un artículo de destino. En segundo lugar, se procesaron las relaciones artículo-categoría desde el archivo “wiki-topcats_Categories.mtx”. Además, se utilizaron los archivos “wiki-topcats_pagenames.txt” y “wiki-

topcats_Category_names.txt” para asociar los identificadores numéricos con nombres comprensibles de artículos y categorías.

Debido al tamaño del dataset original, se trabajó con un subconjunto limitado de datos. Específicamente, se cargaron hasta 10.000 enlaces entre artículos y hasta 10.000 relaciones artículo-categoría. Esta restricción permitió mantener tiempos de ejecución razonables durante el desarrollo, facilitar las pruebas del sistema y conservar un volumen de datos suficiente para realizar un análisis estructural inicial.

Para asegurar la reproducibilidad del análisis, los principales parámetros utilizados durante la ejecución del sistema se resumen en la tabla 2.

Tabla 2. Principales parámetros utilizados durante la ejecución del sistema

Parámetro	Valor utilizado
Enlaces cargados desde wiki-topcats.mtx	10.000
Relaciones artículo-categoría cargadas	10.000
Iteraciones de PageRank	20
Factor de amortiguación	0,85
Representación del grafo	Lista de adyacencia
Librerías de grafos	No utilizadas

Una vez cargados los datos, el programa construye el grafo agregando artículos, categorías, enlaces dirigidos y asociaciones entre artículos y categorías. Para cada enlace procesado, el sistema registra tanto la conexión saliente del artículo de origen como la conexión entrante del artículo de destino. De esta manera, se facilita el cálculo posterior de métricas como grado de entrada y grado de salida.

El flujo general de ejecución del sistema se desarrolló de la siguiente manera:

- Inicialización de una instancia de GrafoArticuloCategoria.
- Lectura de enlaces entre artículos desde el archivo wiki-topcats.mtx.
- Lectura de relaciones artículo-categoría desde el archivo wiki-topcats_Categories.mtx.
- Lectura de nombres de artículos desde wiki-topcats_pagenames.txt.
- Lectura de nombres de categorías desde wiki-topcats_Category_names.txt.
- Creación de objetos de tipo Artículo.
- Creación de objetos de tipo Categoría.
- Inserción de enlaces dirigidos en la lista de adyacencia.
- Asociación entre artículos y categorías.
- Ejecución de recorridos BFS y DFS.
- Verificación de existencia de camino entre dos artículos.
- Cálculo de métricas estructurales, como grado de entrada y grado de salida.
- Cálculo del ranking mediante PageRank simplificado.
- Exportación del ranking obtenido al archivo ranking_pagerank.txt.

Sobre el grafo construido se implementaron algoritmos de recorrido y análisis estructural. El recorrido BFS permite

explorar la red por niveles desde un artículo inicial, mientras que DFS permite recorrer el grafo profundizando por ramas. También se incorporó un método para verificar la existencia de camino entre dos artículos, lo que permite analizar la conectividad dirigida dentro del subconjunto estudiado.

Tabla 3. Algoritmos y métricas implementadas en el sistema.

Algoritmo o métrica	Propósito dentro del sistema
Grado de entrada	Identificar artículos que reciben mayor cantidad de enlaces.
Grado de salida	Identificar artículos que enlazan hacia más artículos.
BFS	Explorar la red por niveles desde un artículo inicial.
DFS	Explorar la red en profundidad desde un artículo inicial.
Existencia de camino	Verificar si un artículo puede alcanzar a otro siguiendo enlaces dirigidos.
PageRank	Estimar la relevancia estructural de los artículos dentro del grafo.

El recorrido BFS permite explorar la red por niveles desde un artículo inicial, priorizando primero los nodos más cercanos. En cambio, DFS permite recorrer el grafo en profundidad, avanzando por una rama antes de retroceder. Ambos recorridos permiten analizar la conectividad del grafo desde distintas perspectivas.

Además, se implementó un método para verificar la existencia de camino entre dos artículos. Esta funcionalidad es relevante porque el grafo es dirigido, por lo que la existencia de una conexión desde un artículo A hacia un artículo B no implica necesariamente que exista un camino inverso.

También se calcularon métricas básicas de conectividad. El grado de entrada permite determinar cuántos artículos apuntan hacia un nodo específico, mientras que el grado de salida indica cuántos enlaces parten desde un artículo hacia otros nodos. Estas métricas permiten identificar artículos con mayor presencia estructural dentro de la red.

Finalmente, se desarrolló una versión simplificada del algoritmo PageRank. Este algoritmo asigna inicialmente un valor uniforme a todos los artículos y luego actualiza iterativamente su importancia considerando los enlaces entrantes y la relevancia de los artículos que los referencian. En la implementación utilizada, PageRank trabaja con un número fijo de iteraciones y un factor de amortiguación, generando como salida un ranking de artículos ordenados según su relevancia estructural dentro del grafo.

Complejidad computacional básica

Desde el punto de vista computacional, la representación mediante lista de adyacencia permite que los recorridos BFS y DFS tengan una complejidad aproximada de $O(V + E)$, donde

V corresponde a la cantidad de artículos y E a la cantidad de enlaces del grafo. Esto se debe a que, durante estos recorridos, cada nodo y cada arista se procesan a lo más una vez.

El cálculo del grado de salida de un artículo se realiza a partir de la cantidad de enlaces almacenados en su lista de adyacencia, mientras que el grado de entrada depende de los enlaces que apuntan hacia dicho artículo. Estas métricas permiten analizar la conectividad de los nodos sin requerir estructuras externas al grafo.

En el caso de PageRank, la complejidad depende del número de iteraciones configuradas, de la cantidad de artículos y de la cantidad de enlaces procesados. En la implementación desarrollada, el cálculo revisa contribuciones entre nodos a partir de las listas de enlaces, por lo que su costo puede aproximarse como $O(k \cdot V \cdot E)$, donde k corresponde al número de iteraciones, V a la cantidad de artículos y E a la cantidad de enlaces. Esta versión resulta suficiente para el subconjunto trabajado, aunque podría optimizarse mediante una estructura explícita de enlaces entrantes.

Validación del sistema

La validación del sistema se realizó mediante la ejecución del archivo principal, verificando que los datos fueran cargados correctamente y que el grafo pudiera construirse sin errores. Posteriormente, se comprobó que los recorridos BFS y DFS entregaran listas de artículos alcanzables desde un nodo inicial, que el método de existencia de camino retornara un valor booleano coherente y que el cálculo de PageRank generara un ranking ordenado de artículos relevantes.

Además, se verificó que el archivo `ranking_pagerank.txt` fuera generado correctamente y que contuviera los artículos con mayor valor de PageRank. Esta salida permitió conservar evidencia de la ejecución del sistema y contrastar los resultados obtenidos con el análisis presentado en el informe.

Tabla 4. Cumplimiento de requerimientos del taller

Requerimiento del taller	Evidencia en el proyecto
Usar Python	Sistema implementado en Python.
Programación orientada a objetos	Clases Artículo, Categoría, GrafoArticuloCategoría y LectorArch.
Construir grafo dirigido	Lista de adyacencia con enlaces artículo-artículo.
No usar librerías de grafos	Implementación manual, sin NetworkX.
Calcular grados	Implementación de grado de entrada y grado de salida.
Implementar BFS y DFS	Recorridos ejecutados desde U.S. Route 166.
Implementar PageRank	Ranking generado con 20 iteraciones y factor 0.85.
Mostrar resultados	Tablas, gráficos y archivo ranking_pagerank.txt.
Relacionar resultados con categorías	Se incorporó una tabla que vincula artículos destacados por PageRank con sus categorías asociadas.

Resultados

Se procesó un subconjunto de 10.000 enlaces del archivo wiki-topcats.mtx y 10.000 relaciones artículo-categoría del archivo wiki-topcats_Categories.mtx. A partir de estos datos se construyó un grafo dirigido, sobre el cual se aplicaron recorridos BFS y DFS, cálculo de grado de entrada, verificación de camino entre artículos y PageRank simplificado.

Tabla 5. Validación de carga de datos. Fuente: elaboración propia.

Elemento	Cantidad
Artículos cargados	14.011
Categorías cargadas	61
Enlaces procesados	10.000
Relaciones artículo-categoría	10.000

La validación de carga permite comprobar que el sistema procesó correctamente el subconjunto definido para el análisis. Se cargaron 14.011 artículos, 61 categorías, 10.000 enlaces entre artículos y 10.000 relaciones artículo-categoría. Estos valores confirman que el grafo fue construido a partir de un volumen de datos suficiente para aplicar recorridos, métricas estructurales y PageRank.

Resultados de recorridos BFS y DFS

Inicialmente, los recorridos BFS y DFS fueron ejecutados desde el primer nodo cargado en el subconjunto. Sin embargo, dicho nodo presentaba grado de salida igual a 1, por lo que el recorrido obtenido fue reducido. Esto significa que el artículo inicial solo poseía un enlace saliente directo dentro del subconjunto

procesado, limitando la cantidad de nodos alcanzables desde ese punto de partida.

Este resultado evidencia que la cantidad de nodos visitados por BFS y DFS depende fuertemente del grado de salida del nodo inicial y de la conectividad posterior de sus vecinos. Por esta razón, para obtener un recorrido más representativo, se ejecutaron ambos algoritmos desde un nodo con mayor conectividad dentro del grafo.

Los recorridos BFS y DFS fueron ejecutados desde el artículo 46, correspondiente a U.S. Route 166. Los primeros diez nodos se muestran en la tabla 6 y la tabla 7

Tabla 6. Primeros 10 nodos visitados mediante BFS desde U.S. Route 166. Fuente: elaboración propia

Orden	ID	Artículo visitado
1	46	U.S. Route 166
2	47	List of Missouri highways
3	13	Missouri Route 117
4	16	Missouri Route 119
5	17	Missouri Route 68
6	25	Missouri Route 114
7	26	Missouri Route 12
8	27	Missouri Route 80
9	28	Missouri Route 75
10	29	Missouri Route 91

Tabla 7. Primeros 10 nodos visitados mediante DFS desde U.S. Route 166. Fuente: elaboración propia

Orden	ID	Artículo visitado
1	46	U.S. Route 166
2	47	List of Missouri highways
3	206	Missouri Route 370
4	85	Missouri Route 103
5	83	Missouri Route 22
6	82	Missouri Route 151
7	51	Missouri Route 77
8	50	Missouri Route 176
9	49	Missouri Route 168
10	48	Missouri Route 92

En el recorrido BFS se observa que el algoritmo explora primero los artículos más cercanos al nodo inicial, visitando principalmente rutas relacionadas con Missouri. En cambio, DFS sigue una trayectoria más profunda dentro del grafo, avanzando por una rama antes de retroceder. La diferencia entre ambos resultados confirma que los recorridos fueron implementados correctamente y que la lista de adyacencia permite explorar la conectividad dirigida entre artículos relacionados temáticamente.

Tabla 8. Prueba de existencia de camino entre artículos. Fuente: elaboración propia.

Elemento	Resultado
Origen	46 - U.S. Route 166
Destino	29 - Missouri Route 91
Existe camino	Sí
Camino encontrado	46 - U.S. Route 166
	47 - List of Missouri highways
	29 - Missouri Route 91

La prueba de existencia de camino confirma que, dentro del subconjunto procesado, existe una ruta dirigida desde U.S. Route 166 hacia Missouri Route 91, pasando por List of Missouri highways. Esto permite verificar que el método opera considerando la dirección de las aristas y que puede identificar conexiones entre artículos no necesariamente inmediatos.

El ranking obtenido mediante PageRank muestra que los artículos con mayor relevancia estructural dentro del subconjunto fueron Buprestidae, Buprestoidea, Visual kei y Schizopodidae. Estos artículos presentan una posición destacada dentro de la red, ya sea por recibir enlaces desde nodos relevantes o por encontrarse dentro de grupos temáticos altamente conectados.

Además del ranking PageRank, se calculó el grado de entrada de los artículos. Esta métrica permite identificar qué nodos reciben mayor cantidad de enlaces directos dentro del subconjunto procesado.




Figura 2. Artículos con mayor grado de entrada dentro del subconjunto analizado. Fuente: elaboración propia

Además del grado de entrada, se calculó el grado de salida de los artículos. Esta métrica permite identificar aquellos nodos que enlazan hacia una mayor cantidad de artículos dentro del subconjunto procesado.




Figura 3. Artículos con mayor grado de salida dentro del subconjunto analizado. Fuente: elaboración propia.




Figura 4. Top 10 artículos con mayor valor de PageRank dentro del subconjunto analizado. Fuente: elaboración propia




Figura 5. Distribución de grados de entrada dentro del subconjunto procesado. Fuente: elaboración propia

Tabla 9. Top 10 artículos con mayor valor de PageRank. Fuente: elaboración propia

Posición	Artículo	PageRank
1	Buprestidae	0.0093829558
2	Buprestoidea	0.0073794644
3	Visual kei	0.0042655368
4	Schizopodidae	0.0040390041
5	Satanic ritual abuse	0.0030912983
6	X Japan	0.0030681726
7	Laboulbeniomycetes	0.0023828623
8	Laboulbeniales	0.0021516020
9	Moral panic	0.0018760295
10	McMartin preschool trial	0.0015757992

Tabla 10. Comparación entre PageRank y grado de entrada. Fuente: elaboración propia.

Artículo	PageRank	Grado de entrada
Buprestidae	0.0093829558	571
Buprestoidea	0.0073794644	536
Visual kei	0.0042655368	156
Schizopodidae	0.0040390041	4
Satanic ritual abuse	0.0030912983	59
X Japan	0.0030681726	158
Laboulbeniomycetes	0.0023828623	149
Laboulbeniales	0.0021516020	147
Moral panic	0.0018760295	125
McMartin preschool trial	0.0015757992	20

Para complementar el análisis de relevancia estructural, se relacionaron los artículos con mayor valor de PageRank con sus categorías asociadas dentro del subconjunto procesado. Esta relación permite interpretar si los nodos más relevantes pertenecen a grupos temáticos específicos y aporta una lectura más completa de los resultados obtenidos.

Tabla 11. Top 10 artículos con mayor valor de PageRank y categorías asociadas

Artículo	PageRank	Categorías asociadas
Buprestidae	0.0093829558	Buprestoidea
Buprestoidea	0.0073794644	Buprestoidea
Visual kei	0.0042655368	Visual_kei_bands
Schizopodidae	0.0040390041	Buprestoidea
Satanic ritual abuse	0.0030912983	Sin categorías
X Japan	0.0030681726	Visual_kei_bands, Japanese_rock_music_groups
Laboulbeniomyces	0.0023828623	Sin categorías
Laboulbeniales	0.0021516020	Laboulbeniomyces
Moral panic	0.0018760295	Sin categorías
McMartin preschool trial	0.0015757992	Sin categorías

La relación entre PageRank y categorías permite complementar el análisis estructural con una interpretación temática de los resultados. Se observa que Buprestidae, Buprestoidea y Schizopodidae se asocian con la categoría Buprestoidea, lo que evidencia un núcleo temático de carácter biológico o taxonómico dentro del subconjunto analizado. Esto indica que varios artículos con alta relevancia estructural no aparecen de forma aislada, sino que pertenecen a un grupo temático común.

Por otra parte, Visual kei y X Japan se relacionan con categorías vinculadas a música japonesa, como Visual kei bands y Japanese rock music groups. Esto muestra que el algoritmo PageRank también permitió identificar relevancia dentro de un núcleo cultural o musical específico. En consecuencia, los artículos destacados por PageRank reflejan distintos grupos temáticos presentes en la red, no únicamente nodos con alta cantidad de enlaces.

Asimismo, algunos artículos con valores relevantes de PageRank, como Satanic ritual abuse, Laboulbeniomyces, Moral panic y McMartin preschool trial, no presentan una categoría registrada dentro del subconjunto procesado. Esto no implica necesariamente que dichos artículos carezcan de categoría en el dataset original, sino que la relación artículo-categoría puede no haber sido incluida debido al límite de lectura aplicado. Por lo tanto, la interpretación temática debe considerarse válida para el subconjunto analizado, pero no necesariamente extensible a la totalidad de Wikipedia.

En conjunto, esta comparación permite observar que PageRank no solo identifica artículos relevantes desde el punto de vista estructural, sino que también ayuda a reconocer posibles núcleos temáticos dentro del grafo. La incorporación de categorías fortalece la interpretación de los resultados, ya que permite pasar de un ranking puramente numérico a una lectura más significativa sobre la organización interna de la red.

La comparación entre PageRank y grado de entrada permite observar que ambas métricas están relacionadas, pero no son equivalentes. Buprestidae y Buprestoidea presentan simultáneamente altos valores de PageRank y alto grado de

entrada, lo que indica que son artículos altamente referenciados y estructuralmente relevantes. Sin embargo, Schizopodidae posee un grado de entrada bajo en comparación con otros artículos, pero alcanza un PageRank elevado, lo que evidencia que la importancia de un nodo no depende únicamente de la cantidad de enlaces recibidos, sino también de la relevancia de los nodos que lo enlazan.

La relación entre PageRank y categorías permite complementar el análisis estructural con una interpretación temática. Se observa que varios artículos destacados pertenecen a grupos específicos: Buprestidae, Buprestoidea y Schizopodidae se asocian con la categoría Buprestoidea, mientras que Visual kei y X Japan se relacionan con categorías vinculadas a música japonesa. También existen artículos con alto PageRank sin categoría registrada dentro del subconjunto procesado, lo que evidencia una limitación derivada del filtro aplicado durante la carga de relaciones artículo-categoría.

Análisis

El análisis de los resultados obtenidos permite observar que la red construida a partir del subconjunto de Wikipedia no presenta una distribución uniforme de conexiones. El gráfico de grado de entrada muestra que ciertos artículos concentran una cantidad considerablemente mayor de enlaces entrantes que el resto. En particular, artículos como Buprestidae y Buprestoidea destacan con valores significativamente superiores, lo que indica que estos nodos son altamente referenciados dentro del subconjunto procesado.

Este comportamiento sugiere que la red posee una estructura desigual, donde la mayoría de los artículos tiene baja conectividad y unos pocos actúan como puntos de concentración. Este patrón es habitual en redes reales de información, ya que no todos los nodos cumplen el mismo rol dentro de la estructura. Algunos artículos funcionan como referencias centrales dentro de un grupo temático, mientras que otros aparecen como nodos periféricos con menor cantidad de conexiones.

El grado de entrada permitió identificar artículos que reciben una alta cantidad de enlaces desde otros nodos. Sin embargo, esta métrica por sí sola no permite determinar completamente la relevancia estructural de un artículo, ya que solo considera la cantidad de enlaces recibidos y no la importancia de los nodos que generan dichos enlaces. Por esta razón, el uso de PageRank permitió complementar el análisis con una medida más refinada de relevancia. El grado de salida complementa este análisis, ya que permite identificar artículos que actúan como puntos de expansión dentro de la red. En los resultados obtenidos, artículos como Agrilinae, Buprestinae, List of Laboulbeniaceae genera y Chrysochroinae presentan altos valores de grado de salida, lo que indica que enlazan hacia una mayor cantidad de artículos dentro del subconjunto. A diferencia del grado de entrada, que mide cuántas referencias recibe un nodo, el grado de salida permite reconocer artículos que funcionan como distribuidores de enlaces hacia otros contenidos.

Los resultados obtenidos mediante PageRank muestran que los artículos Buprestidae, Buprestoidea, Visual kei, Schizopodidae y Satanic ritual abuse se encuentran entre los nodos con

mayor importancia estructural dentro del subconjunto analizado. Esto indica que dichos artículos no solo reciben enlaces, sino que además se encuentran relacionados con nodos que también poseen peso dentro de la red. En consecuencia, PageRank entrega una interpretación más profunda que el simple conteo de enlaces entrantes.

La comparación entre PageRank y grado de entrada muestra que existe una relación parcial entre ambas métricas. Buprestidae y Buprestoidea ocupan posiciones destacadas en ambos indicadores, lo que sugiere que son nodos altamente referenciados y estructuralmente importantes. Sin embargo, el caso de Schizopodidae demuestra que PageRank no equivale simplemente a contar enlaces entrantes, ya que este artículo obtiene un valor alto de relevancia pese a tener un grado de entrada considerablemente menor. Esto confirma que PageRank pondera la calidad de los enlaces recibidos, no solo su cantidad.

Los recorridos BFS y DFS permitieron analizar la conectividad del grafo desde una perspectiva distinta. Inicialmente, al ejecutar los recorridos desde un nodo con grado de salida igual a 1, se obtuvo una exploración muy reducida. Este resultado evidencia que, en grafos dirigidos, la amplitud del recorrido depende directamente del nodo inicial seleccionado y de sus enlaces salientes. Si un nodo posee pocas conexiones hacia otros artículos, el recorrido queda limitado aunque el grafo completo contenga muchas relaciones.

Al ejecutar BFS y DFS desde U.S. Route 166, se obtuvo una exploración más amplia y temáticamente coherente. En ambos recorridos aparecieron principalmente artículos relacionados con rutas y carreteras de Missouri, como List of Missouri highways, Missouri Route 117, Missouri Route 119 y Missouri Route 370. Esto demuestra que la estructura del grafo conserva relaciones temáticas entre artículos, ya que los nodos alcanzados desde el punto de partida pertenecen a un mismo contexto semántico. La diferencia entre BFS y DFS también se observa en el orden de visita. BFS exploró primero los artículos más cercanos al nodo inicial, priorizando los vecinos directos antes de avanzar hacia niveles más profundos. En cambio, DFS avanzó por una rama específica del grafo antes de retroceder y explorar otras posibilidades. Esta diferencia confirma que ambos algoritmos funcionan correctamente y que permiten estudiar la conectividad de la red desde enfoques complementarios.

La prueba de existencia de camino permitió comprobar que existe una ruta dirigida desde U.S. Route 166 hacia Missouri Route 91, pasando por List of Missouri highways. Este resultado es relevante porque confirma que el sistema puede identificar conexiones entre artículos no necesariamente inmediatos, respetando la dirección de las aristas del grafo. Además, el camino encontrado resulta temáticamente coherente, ya que conecta una ruta específica con una lista general de carreteras de Missouri y luego con otra ruta del mismo estado. La relación entre PageRank y categorías permitió complementar el análisis estructural con una interpretación temática. Los artículos Buprestidae, Buprestoidea y Schizopodidae aparecen vinculados con la categoría Buprestoidea, lo que evidencia la presencia de un núcleo temático de carácter biológico o taxonómico. Por otra parte, Visual kei y X Japan se asocian con categorías relacionadas con música japonesa, como Visual kei bands y

Japanese rock music groups. Asimismo, Laboulbeniales aparece asociado con Laboulbeniomyces, reforzando la presencia de grupos temáticos específicos dentro de los artículos destacados.

Los casos de Satanic ritual abuse, Laboulbeniomyces, Moral panic y McMartin preschool trial muestran que algunos artículos pueden alcanzar valores relevantes de PageRank aun cuando no posean una categoría registrada dentro del subconjunto procesado. Esto no implica necesariamente que carezcan de categoría en el dataset original, sino que dicha relación puede no haber sido incluida debido al límite de lectura aplicado sobre las relaciones artículo-categoría. Por lo tanto, los resultados deben interpretarse considerando el alcance parcial del subconjunto utilizado.

La distribución de grados refuerza esta interpretación general. La mayor parte de los artículos presenta pocos enlaces entrantes, mientras que un grupo reducido concentra una cantidad considerable de conexiones o relevancia estructural. Este comportamiento permite identificar una red con nodos centrales y nodos periféricos, lo cual es consistente con estructuras reales de información, donde ciertos contenidos actúan como puntos de referencia para múltiples artículos relacionados. En conjunto, los resultados permiten afirmar que el sistema no solo construye correctamente el grafo dirigido, sino que también genera información interpretable sobre la estructura de la red. Las métricas de grado permiten identificar patrones de conectividad, los recorridos BFS y DFS permiten explorar caminos y zonas temáticas, la prueba de existencia de camino verifica conectividad dirigida, y PageRank permite estimar la relevancia estructural de los artículos. Además, la relación con categorías aporta una lectura temática que fortalece la interpretación de los resultados obtenidos.

Limitaciones del análisis

Los resultados obtenidos deben interpretarse considerando que se trabajó con un subconjunto de 10.000 enlaces y 10.000 relaciones artículo-categoría, por lo que no representan la totalidad de Wikipedia. Además, la implementación de PageRank utiliza un número fijo de iteraciones y no incorpora un criterio automático de convergencia. Finalmente, la presencia de nodos sin enlaces salientes puede afectar la redistribución de importancia dentro del algoritmo, por lo que este aspecto debería revisarse en futuras versiones del sistema.

Conclusiones

El proyecto permitió desarrollar un sistema funcional en Python capaz de modelar y analizar una red de artículos de Wikipedia mediante un grafo dirigido. A partir de datos reales del dataset Graphs SNAP Wiki, se logró construir una estructura que representa artículos, enlaces y categorías, cumpliendo con los objetivos centrales del taller de Programación Científica.

Una de las principales conclusiones es que la programación orientada a objetos resultó adecuada para representar el dominio del problema. La separación entre artículos, categorías y grafos permitió organizar el código de manera clara, modular y coherente. Esta estructura facilita la comprensión del sistema, evita mezclar responsabilidades y permite que futuras

mejoras puedan incorporarse sin modificar completamente la arquitectura existente.

La representación mediante listas de adyacencia fue una decisión apropiada para trabajar con una red de gran tamaño. Esta estructura permite almacenar los enlaces dirigidos de forma eficiente y aplicar algoritmos de recorrido y análisis sin utilizar librerías externas de grafos. De esta manera, el proyecto cumple con la restricción académica de implementar manualmente la lógica del grafo y, al mismo tiempo, permite comprender con mayor profundidad cómo se almacenan y recorren este tipo de estructuras.

Los algoritmos BFS y DFS permitieron comprobar que el grafo construido puede ser recorrido desde distintos nodos, lo que evidencia que la estructura interna funciona correctamente para explorar conexiones entre artículos. Asimismo, el método de existencia de camino permitió analizar la posibilidad de llegar desde un artículo a otro siguiendo la dirección de los enlaces. Esto refuerza la importancia de considerar la direccionalidad del grafo, ya que las relaciones entre artículos de Wikipedia no necesariamente son recíprocas.

El cálculo de métricas de grado permitió obtener una primera caracterización estructural de la red. El grado de entrada permitió identificar artículos referenciados por otros nodos, mientras que el grado de salida permitió reconocer artículos que enlazan hacia otros contenidos. Estas métricas son fundamentales para comprender la conectividad básica del grafo y sirven como base para interpretar resultados más complejos, como los entregados por PageRank.

La implementación de PageRank permitió identificar artículos relevantes dentro del subconjunto procesado. Los resultados muestran que artículos como Buprestidae y Buprestoidea obtuvieron los valores más altos, lo que indica que poseen una posición estructural importante dentro de la red analizada. Este resultado demuestra que la relevancia de un artículo no depende exclusivamente de su popularidad temática, sino de su posición dentro de la estructura de enlaces. En este sentido, PageRank entrega una medida más refinada que el simple conteo de enlaces entrantes.

La relación entre PageRank y categorías permitió complementar el análisis estructural con una interpretación temática. Se observó que artículos como Buprestidae, Buprestoidea y Schizopodidae se agrupan en torno a la categoría Buprestoidea, mientras que Visual kei y X Japan se relacionan con categorías asociadas a música japonesa. Esto demuestra que los artículos relevantes no aparecen de forma aislada, sino que pueden formar parte de núcleos temáticos dentro del grafo.

También se concluye que el subconjunto analizado presenta una distribución desigual de conectividad. La mayoría de los artículos posee baja cantidad de enlaces entrantes, mientras que unos pocos concentran mayor relevancia estructural. Este comportamiento es coherente con redes reales de información, donde suelen existir nodos altamente conectados y muchos nodos periféricos. Por ello, el análisis realizado permite observar patrones propios de redes complejas, aun trabajando con una porción limitada del dataset original.

El proyecto cumple con los principales requerimientos del taller: utiliza Python, aplica programación orientada a objetos,

construye un grafo dirigido desde datos reales, calcula métricas estructurales, implementa BFS y DFS, aplica PageRank, genera resultados por consola y exporta un ranking a archivo. Además, el desarrollo evita el uso de librerías especializadas de grafos, lo que permite demostrar una comprensión directa de las estructuras y algoritmos implementados.

Sin embargo, los resultados deben interpretarse considerando ciertas limitaciones metodológicas. Al trabajar con un subconjunto de datos, las conclusiones obtenidas describen únicamente la porción de red procesada y no la totalidad de Wikipedia. Además, PageRank fue implementado en una versión simplificada, por lo que podría fortalecerse mediante criterios de convergencia, una gestión más completa de nodos sin enlaces salientes y una optimización del cálculo de contribuciones entre nodos. Como mejora futura, sería recomendable ampliar el análisis artículo-categoría a una mayor cantidad de nodos, incorporando más categorías por artículo y evaluando si los núcleos temáticos observados se mantienen al aumentar el tamaño del subconjunto procesado.

Finalmente, este trabajo permitió integrar contenidos fundamentales de programación científica, tales como carga de datos, modelado orientado a objetos, estructuras de datos, recorridos de grafos, métricas estructurales, algoritmos iterativos y análisis de resultados. En consecuencia, el sistema desarrollado no solo cumple con los requerimientos técnicos del taller, sino que también demuestra que una red real puede ser modelada, recorrida e interpretada mediante estructuras de datos implementadas manualmente. La combinación entre métricas de grado, recorridos, PageRank y categorías permitió obtener una lectura integral del subconjunto analizado.

References

- [1] Wolfram77. (s.f.). *Wikipedia link Graphs (SNAP)*. Kaggle. Recuperado de <https://www.kaggle.com/datasets/wolfram77/graphs-snap-wiki>
- [2] Stanford Network Analysis Project. (s.f.). *wiki-topcats network*. SNAP: Stanford Large Network Dataset Collection. Recuperado de <https://snap.stanford.edu/data/wiki-topcats.html>
- [3] Python Software Foundation. (s.f.). *Python 3 Documentation*. Recuperado de <https://docs.python.org/3/>
- [4] Cormen, T. H., Leiserson, C. E., Rivest, R. L., & Stein, C. (2009). *Introduction to Algorithms* (3rd ed.). MIT Press.
- [5] Newman, M. E. J. (2018). *Networks* (2nd ed.). Oxford University Press.
- [6] Page, L., Brin, S., Motwani, R., & Winograd, T. (1999). *The PageRank citation ranking: Bringing order to the web*. Stanford InfoLab.
- [7] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.